Contexto y Situación del Reto

Demanda de bicicletas compartidas y rebalanceo en Nueva York

Citi Bike es el sistema de bicicletas compartidas de la Ciudad de Nueva York, y uno de los más utilizados de Estados Unidos. Su operación depende de una condición muy sencilla de enunciar y muy difícil de cumplir: que haya una bicicleta disponible en la estación donde el usuario la busca y un anclaje libre en la estación donde quiere dejarla. La demanda, sin embargo, no se reparte de manera uniforme ni en el espacio ni en el tiempo. Por la mañana los viajes fluyen desde zonas residenciales hacia zonas de oficinas, por la tarde ocurre lo contrario, y la lluvia, el frío, los días festivos o un evento masivo pueden cambiar por completo el patrón de un día a otro.

El resultado son estaciones que se vacían y estaciones que se llenan. Una estación vacía significa un usuario que no puede iniciar su viaje; una estación llena significa un usuario que no puede terminarlo. Para corregirlo, el operador debe redistribuir bicicletas entre estaciones (rebalanceo), una tarea costosa que requiere vehículos, personal y tiempo. Saber qué estaciones necesitarán más o menos bicicletas, y en qué franja horaria, permite pasar de un rebalanceo reactivo a uno planeado. Quienes se benefician de ello son el equipo de operaciones del sistema, los planificadores urbanos que deciden dónde ampliar o reubicar estaciones, y los propios usuarios.

El nivel estación-hora y la incertidumbre

Trabajar a nivel de estación y hora es importante porque es la unidad en la que se toman las decisiones operativas. Un promedio para toda la ciudad, o incluso por barrio (borough), oculta justamente lo que importa: dos estaciones separadas por pocas cuadras pueden tener patrones de uso radicalmente distintos, una que funciona como origen de viajes de commuting y otra como destino de turismo o recreación.

Este nivel de detalle implica también un reto importante: la incertidumbre. Algunas estaciones registran miles de viajes al mes y otras solo unas decenas, por lo que sus predicciones son inherentemente más variables, y métricas como el MAPE pueden dispararse cuando la demanda observada es cercana a cero. Además, los datos de viajes registran únicamente la demanda satisfecha: si una estación estaba vacía, los viajes que no ocurrieron no aparecen en ninguna parte. Ignorar estos matices puede llevar a confiar en pronósticos que parecen precisos en promedio pero que fallan en las estaciones y horarios donde más se necesitan. Por ello se espera que el análisis reporte el error del modelo de manera desagregada (por estación, por hora y por tipo de día) y, en lo posible, intervalos de predicción en lugar de un único número.

Los datos disponibles y su naturaleza

Para abordar el reto se cuenta con una fuente principal pública y tres complementos opcionales:

- **Citi Bike Trip Histories (fuente principal).** Historial de viajes publicado por Citi Bike en https://citibikenyc.com/system-data. Cada fila es un viaje con su fecha y hora de inicio y fin, estación y coordenadas de origen y destino, tipo de bicicleta (clásica o eléctrica) y tipo de usuario (miembro u ocasional). Según la propia fuente, los datos ya fueron depurados para excluir viajes del personal de servicio, viajes desde o hacia estaciones de prueba y viajes de menos de 60 segundos. Los archivos se distribuyen por periodo (anuales en los primeros años y mensuales en los más recientes) y los meses con más de un millón de viajes se dividen en varios CSV dentro del mismo archivo comprimido.

- **Clima histórico (opcional).** Temperatura, precipitación y viento por hora o por día, obtenibles de fuentes como NOAA u Open-Meteo, que se integran por fecha y hora con cada viaje.

- **Calendario (opcional).** Días festivos y fines de semana, para capturar cambios en el patrón de uso.

- **Feed en tiempo real GBFS (opcional).** Citi Bike publica además información en tiempo real en formato General Bikeshare Feed Specification, útil como idea de siguiente paso para llevar el modelo a producción, ya que el historial de viajes por sí solo no contiene el inventario de bicicletas por estación.

Un punto crítico de la fuente principal es que el esquema de columnas cambió a partir de febrero de 2021: los archivos anteriores incluyen duración del viaje, identificador de bicicleta, tipo de usuario (Subscriber o Customer), género y año de nacimiento, mientras que los posteriores incluyen identificador de viaje, tipo de bicicleta y tipo de usuario (member o casual). Si el equipo decide trabajar con varios años, deberá armonizar ambos formatos, por ejemplo equiparando Subscriber con member y Customer con casual.

La brecha que el reto busca cerrar

Actualmente, una persona interesada en entender y anticipar la demanda del sistema tendría que descargar decenas de archivos por separado, lidiar con esquemas que cambian entre periodos, procesar cientos de millones de filas que no caben cómodamente en una hoja de cálculo, limpiar viajes con valores faltantes o inconsistentes, incorporar variables externas como el clima y, finalmente, decidir cómo traducir todo eso en una recomendación concreta. Todo esto sin contar con una herramienta que permita explorar los resultados de manera visual e interactiva.

Este reto busca cerrar precisamente esa brecha. La propuesta consiste en construir, mediante código, un flujo completo que unifique las fuentes en una base de datos eficiente (por ejemplo, Parquet o DuckDB), analice las tendencias de uso, entrene modelos de Machine Learning y presente los resultados en un dashboard que permita a un analista de operaciones, sin necesidad de escribir código, ver dónde y cuándo se concentrará la demanda y cuántas bicicletas necesita cada estación.

El objetivo no es únicamente realizar un ejercicio técnico de limpieza y entrenamiento de modelos, sino desarrollar una herramienta útil para la toma de decisiones. El resultado esperado es un conjunto de modelos estadísticamente sólidos, validados con un esquema temporal y evaluados con métricas adecuadas; geográficamente navegable, permitiendo explorar rutas y estaciones sobre un mapa; y sobre todo accionable. Es decir, que la herramienta no solo muestre dónde se concentra la demanda, sino también qué la explica (hora, tipo de usuario, clima, tipo de estación) para sugerir una estrategia distinta de rebalanceo según el tipo de estación. También se espera un pitch en video de máximo 5 minutos.

Tareas de modelado

El equipo puede abordar una o varias de las siguientes tareas, siempre comparando contra un baseline simple (por ejemplo, el promedio histórico por estación, hora y día de la semana) y contra al menos un modelo más complejo (XGBoost, LightGBM, Prophet o redes recurrentes):

Tarea	Tipo de problema	Métricas sugeridas
Duración del viaje	Regresión	MAE, RMSE
Estación de destino (dado origen, hora y tipo de usuario)	Clasificación multiclase	Accuracy@k (top-k), F1 ponderado
Demanda por hora y por estación	Series de tiempo / regresión con variables temporales y climáticas	MAE, RMSE, MAPE (con cuidado en demanda cercana a cero)
Bicicletas necesarias por estación y franja horaria	Regresión / optimización para rebalanceo	MAE por estación, cobertura de intervalos de predicción

Cuadro 1: Tareas de modelado y métricas sugeridas

Glosario de Variables

Dataset Citi Bike Trip Histories (formato actual, desde febrero de 2021)

Columna	Tipo	Descripción
ride_id	str	Identificador único del viaje. Sirve como índice; no permite seguir a una misma bicicleta.
rideable_type	str	Tipo de bicicleta utilizada (ej. classic_bike, electric_bike).
started_at	datetime	Fecha y hora de inicio del viaje.
ended_at	datetime	Fecha y hora de fin del viaje.
start_station_name	str	Nombre de la estación de origen.
start_station_id	str	Identificador de la estación de origen.
end_station_name	str	Nombre de la estación de destino.
end_station_id	str	Identificador de la estación de destino.
start_lat	float64	Latitud del punto de inicio del viaje.

start_lng	float64	Longitud del punto de inicio del viaje.
end_lat	float64	Latitud del punto de término del viaje.
end_lng	float64	Longitud del punto de término del viaje.
member_casual	str	Tipo de usuario: member (miembro) o casual (ocasional).

Cuadro 2: Glosario de columnas – Citi Bike Trip Histories (formato actual)

Nota: algunos viajes pueden presentar valores faltantes en estación o coordenadas, por lo que se recomienda verificarlo durante la limpieza.

Dataset Citi Bike Trip Histories (formato anterior, hasta enero de 2021)

Solo es relevante si el equipo decide incluir años anteriores. Los nombres exactos de las columnas pueden variar entre archivos, por lo que deben verificarse antes de la integración.

Campo	Descripción
Duración del viaje	Duración del viaje en segundos.
Fecha y hora de inicio y de fin	Equivalentes a started_at y ended_at.
Estación de origen y destino (ID, nombre, latitud, longitud)	Equivalentes a las columnas de estación y coordenadas del formato actual.
Bike ID	Identificador de la bicicleta; permite seguirla entre viajes.
User Type	Customer (pase de 24 horas o 7 días) o Subscriber (miembro anual); equivalentes a casual y member.
Gender, Year of Birth	Género y año de nacimiento del usuario; no existen en el formato actual.

Cuadro 3: Campos del formato anterior de Citi Bike Trip Histories

Variables derivadas sugeridas

Variable	Tipo	Descripción
trip_duration_min	float64	Duración del viaje en minutos, calculada como ended_at - started_at. Se recomienda filtrar valores atípicos.
hour, weekday, month	int	Componentes temporales extraídos de started_at.
is_holiday	bool	Indica si la fecha es día festivo.
distance_km	float64	Distancia entre estación de origen y destino (por ejemplo, fórmula de Haversine).
demand_station_hour	int	Número de viajes iniciados en una estación en una hora determinada.
net_flow_station_hour	int	Llegadas menos salidas de una estación en una hora; base para estimar la necesidad de rebalanceo.

temperature, precipitation	float64	Variables climáticas opcionales integradas por fecha y hora.

Cuadro 4: Variables derivadas sugeridas

Entregable

De este DataRush se espera:

- Video pitch con duración máxima de 5 minutos
- Dashboard/App/Notebook como propuesta final del reto
- Notebook(s) reproducible(s) con el flujo de limpieza, modelado y evaluación
- Liga de repositorio en GitHub: carpetas completas del proyecto

SUBMIT HERE:

Rúbrica

No.	Rubro	Criterios	Máx. calif.
1	**Pitch**	Que el equipo comunique el problema con claridad desde el inicio: quién se beneficia (por ejemplo, el equipo de operaciones del sistema) y con qué decisión concreta (por ejemplo, cuántas bicicletas mover a cada estación y cuándo). La narrativa debe seguir forma de storytelling con datos e incluir al menos un hallazgo real en estos. Se valora buen manejo de la información, claridad con el punto/mensaje y un cierre conciso. Límite de pitch en video de 5 minutos (-5 si se pasa).	35
2	**Dashboard/app/notebook final (demo en vivo)**	Que se vea profesional y funcione sin errores en vivo. El dashboard o presentación debe comunicar el problema de un vistazo, sin necesidad de explicación: estaciones y rutas más usadas, y zonas y horarios de mayor demanda. Debe mostrar la información de estaciones y rutas. Considere la incertidumbre de los pronósticos (intervalos de predicción o error por estación y hora).	35
3	**Impacto y accionabilidad**	Se busca que el equipo tenga un caso de uso concreto y creíble, no una idea vaga o abierta a interpretación. El dashboard debe mostrar no solo dónde y cuándo se concentra la demanda, sino qué la causa (hora, tipo de usuario, clima, tipo de estación), para sugerir una acción distinta en cada caso. Se valora que el equipo tenga claro cuál sería el siguiente paso del proyecto.	15
4	**Checklist técnico (datos/ML)**	Revisión rápida. Se busca evidencia de un flujo de datos limpio y reproducible: integración de los archivos, manejo de esquemas distintos y valores faltantes, pureza de los datos trabajados y entendimiento del proceso detrás del dashboard. En el modelado se valora el rigor: línea base,	15

		comparación de al menos dos modelos, validación temporal (sin fuga de información) y métricas adecuadas.	

Cuadro 5: Rúbrica de evaluación